

# Optimización del Flujo de Atención al Cliente con NLP

## Resumen Ejecutivo

La satisfacción del cliente depende en gran medida de la rapidez y precisión con la que se gestionan sus solicitudes de soporte. Dado que los tickets pueden abarcar temas muy diversos, resulta fundamental clasificarlos de forma eficiente y asignarlos al agente o departamento más adecuado cuanto antes. Una distribución lenta o incorrecta no solo afecta a los tiempos de resolución, sino que también reduce la calidad global del servicio.

El objetivo principal de este estudio es explorar cómo automatizar la categorización de solicitudes para mejorar la asignación de tareas dentro de los equipos de atención al cliente. Para ello se analizan los procesos actuales de gestión de tickets, considerando la estructura de colas, los niveles de prioridad, los idiomas de comunicación y el uso de etiquetas manuales. A partir de estos elementos, el estudio evalúa la utilidad de técnicas de análisis de texto, métodos de *clustering* y modelos de clasificación para optimizar indicadores clave del soporte técnico, como el tiempo de primera respuesta, el tiempo total de resolución, la distribución de la carga entre equipos y la coherencia en la asignación temática de los tickets.

La metodología empleada combina EDA (*Exploratory Data Analysis*), normalización de etiquetas, modelos de vectorización de texto (*embedding*) y algoritmos de *clustering*, junto con visualizaciones en baja dimensionalidad mediante UMAP. Estos métodos permiten revelar patrones temáticos y comprender la estructura real del flujo de solicitudes.

Los resultados muestran que la clasificación actual no refleja de manera adecuada la temática de los tickets y que las etiquetas manuales son incompletas e inconsistentes. Esto pone de manifiesto la necesidad de incorporar sistemas automáticos capaces de realizar una clasificación más precisa y un encaminamiento inteligente, contribuyendo así a un flujo de atención más eficiente y a una experiencia de soporte más coherente y ágil.

## Introducción

### Contexto y Relevancia

Las empresas que gestionan grandes volúmenes de solicitudes de usuarios se enfrentan al problema de distribuir adecuadamente los tickets entre colas y especialistas. En situaciones de alta carga, es esencial identificar rápidamente el tema del ticket para enviarlo al departamento correcto. Si este proceso falla, aumenta el tiempo de resolución, crece el número de escalaciones y disminuye la calidad del servicio.

La relevancia de este estudio radica en que los sistemas tradicionales de colas y etiquetas manuales suelen reflejar la estructura interna de la empresa, pero no el contenido real de las solicitudes. Como consecuencia, un mismo tipo de problema puede ser enviado a diferentes colas, y una misma cola puede recibir tickets que difieren considerablemente en su temática. Esto produce un flujo inconsistente y reduce la eficiencia del soporte.

### Problema de Investigación y Objetivos

El problema central de la investigación es que los métodos actuales de enrutamiento no están alineados con la semántica real de los tickets. El propósito del estudio es analizar la estructura de las solicitudes, identificar grupos temáticos reales y evaluar en qué medida las colas existentes coinciden con el contenido de los tickets.

## Metodología

### Fuente y Datos

El estudio utiliza un conjunto de datos compuesto por 28 587 solicitudes sintetizadas. Cada ticket incluye los campos *subject*, *body*, *answer*, *type*, *queue*, *priority*, *language*, *version* y ocho etiquetas manuales *tag\_1* – *tag\_8* (véase Tabla 1).

| Variable      | Tipo de datos    | Descripción                                                                                                                      |
|---------------|------------------|----------------------------------------------------------------------------------------------------------------------------------|
| subject       | Categorico       | Asunto de la carta                                                                                                               |
| body          | Categorico       | Contenido completo de la carta con caracteres especiales legibles por máquina, enlaces, saltos de línea                          |
| answer        | Categorico       | Respuesta del personal de soporte técnico con caracteres especiales legibles por máquina, enlaces, saltos de línea               |
| type          | Categorico       | Tipo de solicitud expresada en la categoría de incidente, solicitud, problema o cambio                                           |
| queue         | Categorico       | Una cola de solicitudes determinada no por los tipos de solicitudes entrantes, sino por la lógica empresarial de la organización |
| priority      | Número(Discreto) | La prioridad del recurso demuestra la urgencia de la decisión                                                                    |
| language      | Categorico       | Idioma de comunicación: inglés, alemán                                                                                           |
| version       | Número(Discreto) | La versión del software que está utilizando el usuario                                                                           |
| tag_1 - tag_8 | Categorico       | Etiquetas para el asunto real de la solicitud de un cliente, asignadas manualmente por el personal de soporte                    |

Tabla 1

## Herramientas y Técnicas de Análisis

Todos los experimentos se realizaron en *Python 3.11* utilizando *Jupyter Notebook*. Se emplearon *pandas*, *numpy*, *scikit-learn*, *matplotlib*, *seaborn* y *sentence-transformers*. Este conjunto de herramientas permite reproducir completamente el estudio en cualquier entorno estándar de *Python*.

1. **Análisis exploratorio (EDA).** En esta etapa se estudiaron los valores faltantes, la distribución por colas, prioridades, idiomas y el nivel de consistencia en el uso de etiquetas. Esta fase permitió evaluar la calidad de los datos y detectar características estructurales del flujo actual de tickets, lo que ayudó a definir las herramientas adecuadas para las etapas siguientes.
2. **Normalización de etiquetas.** Dado que las etiquetas se asignan manualmente, eran frecuentes los duplicados, variantes de escritura y errores tipográficos. Las etiquetas fueron pasadas a minúsculas, limpiadas de símbolos innecesarios y agrupadas por significado, lo que redujo su variedad y mejoró su utilidad para el análisis.
3. **Análisis de texto.** Para obtener una representación semántica de cada ticket se utilizaron modelos de *embedding*. Cada texto fue transformado en un vector numérico mediante el modelo Sentence Transformers: *distiluse-base-multilingual-cased-v2*, que soporta múltiples idiomas y proporciona *embeddings* universales de buena calidad. El resultado fueron vectores de 512 elementos tipo float para cada ticket.
4. **Clustering.** Para agrupar tickets por similitud semántica se empleó el algoritmo *K-Means*. El número óptimo de *clusters* se determinó experimentalmente usando la métrica de silueta. Las agrupaciones fueron visualizadas mediante UMAP, un método de reducción de dimensionalidad que representa datos de alta dimensión como un mapa en dos dimensiones conservando su estructura semántica.
5. **Análisis predictivo** para definir la cola adecuada a partir del texto del ticket. Se utilizaron *Logistic Regression*. Los datos fueron divididos en conjuntos de entrenamiento y prueba, y la calidad de los modelos se evaluó mediante *accuracy*, *precision*, *recall* y *F1-score*.

Los resultados obtenidos muestran que la asignación actual de tickets no coincide con la temática real, y que las etiquetas manuales no son fiables, lo cual confirma la necesidad de implementar sistemas automáticos de clasificación y enrutamiento inteligente.

## Resultados

El gráfico de distribución de tickets por colas revelan una sobrecarga significativa en la cola *Technical Support* y una diferencia notable con respecto a otras áreas.




Figura 1

El análisis por prioridades muestra que los tickets urgentes suelen enviarse a las colas más saturadas.




Figura 2

La distribución por idiomas indica que las solicitudes llegan en volúmenes similares en varios idiomas, principalmente inglés y alemán, lo que justifica el uso de modelos multilingües.




Figura 3

El análisis de valores faltantes muestra que muchas solicitudes no contienen un conjunto completo de etiquetas. Las primeras cuatro etiquetas se rellenan con regularidad, mientras que las últimas casi no se utilizan.




Figura 4

El análisis de frecuencia de etiquetas mostró que el top-20 parece estructurado, pero un 17% de los tickets contiene etiquetas únicas, raras o con errores tipográficos.




Figura 4, Figura 5, Figura 6

El tráfico del UMAP muestra que las colas están distribuidas de forma caótica dentro de los grupos temáticos. La temática de los tickets y las colas no coinciden.




Figura 7

El *clustering* con *embeddings* reveló nueve grupos temáticos bien definidos. UMAP visualiza estos grupos de forma clara y sin superposición.




Figura 8

El modelo Logistic Regression obtuvo métricas consistentemente altas en todas las categorías temáticas definidas por *cluster\_name*, mostrando un desempeño uniforme en la clasificación de los distintos grupos.




Figura 9

## Interpretación de los Resultados

La estructura actual de colas no coincide con el contenido real de los tickets. Algunas colas tienen una identidad temática clara, mientras que otras mezclan solicitudes de diferentes tipos. Esto genera errores de asignación, incrementa los tiempos de resolución y aumenta la carga en los departamentos más saturados.

Los *clusters* obtenidos mediante *embedding* muestran áreas temáticas bien definidas que representan mejor la estructura real del flujo de tickets que las colas actuales. Esto coincide con estudios previos que demuestran que la clasificación temática mejora KPI como el tiempo de primera respuesta, tiempo de resolución, número de escalaciones y distribución de carga.

Los resultados del modelo de clasificación entrenado sobre *cluster\_name* muestran que las categorías temáticas generadas mediante *embeddings* y *clustering* son coherentes, separables y representan con precisión el contenido real de los tickets. Los valores elevados de precision, recall y F1 en todas las clases indican que cada grupo temático posee una identidad semántica clara y que los límites entre categorías están bien definidos. Esto confirma que la segmentación temática obtenida en la fase de *clustering* refleja de forma fiable los diferentes tipos de solicitudes de los usuarios.

Además, el rendimiento del modelo valida la calidad de los *embeddings* utilizados: el sistema es capaz de identificar con gran exactitud temas como incidencias críticas, fallos de red, solicitudes de mejora, seguridad o cuestiones de facturación. La consistencia de estas predicciones coincide con trabajos previos que destacan la utilidad del análisis semántico para mejorar la organización y el tratamiento de grandes volúmenes de tickets.

## Implicaciones Practicas

Los resultados sugieren que un sistema basado en *embeddings* y clasificación automática puede utilizarse como mecanismo robusto para la categorización temática de solicitudes en entornos reales de soporte. La alta precisión del modelo indica que es posible automatizar la identificación del tipo de incidencia, reducir la necesidad de etiquetado manual y mejorar la coherencia en la gestión del flujo de tickets.

Asimismo, la estructura temática obtenida proporciona una base sólida para diseñar procesos de enrutamiento más eficientes, priorizar incidencias y distribuir la carga de trabajo entre equipos especializados. Estos resultados abren la puerta a la integración de sistemas inteligentes de clasificación que contribuyan a acelerar la atención, mejorar la calidad del servicio y optimizar el uso de recursos en los equipos de soporte.

## Referencias

- Aggarwal, C. (2018). Machine learning for text. Springer.
- Arias-Barahona, M. X., Arteaga-Arteaga, H. B., Orozco-Arias, S., Flórez-Ruiz, J. C., Valencia-Díaz, M. A., & Tabares-Soto, R. (2023). Requests classification in the customer service area for software companies using machine learning and natural language processing. PeerJ Computer Science. [<https://pmc.ncbi.nlm.nih.gov/articles/PMC10280277/>](<https://pmc.ncbi.nlm.nih.gov/articles/PMC10280277/>)
- Conneau, A., et al. (2020). Unsupervised cross-lingual representation learning at scale. arXiv. [<https://arxiv.org/abs/1911.02116>](<https://arxiv.org/abs/1911.02116>)
- Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). BERT: Pre-training of deep bidirectional transformers for language understanding. arXiv. [<https://arxiv.org/abs/1810.04805>](<https://arxiv.org/abs/1810.04805>)
- IBM Research. (2019). Automatic ticket classification using machine learning. [<https://arxiv.org/abs/1902.02215>](<https://arxiv.org/abs/1902.02215>)
- Kowsari, K., et al. (2019). Text classification algorithms: A survey. Information. [<https://doi.org/10.3390/info10040150>](<https://doi.org/10.3390/info10040150>)
- Kumar, A., & Singh, P. (2021). Automated IT ticket assignment using NLP and classification models. Springer. [[https://doi.org/10.1007/978-981-15-8354-4\\_23](https://doi.org/10.1007/978-981-15-8354-4_23)]([https://doi.org/10.1007/978-981-15-8354-4\\_23](https://doi.org/10.1007/978-981-15-8354-4_23))
- Marcus, L. (2023). Using NLP (Natural Language Processing) to improve field service operations. Medium. [<https://liron-marcus.medium.com/using-nlp-natural-language-processing-to-improve-field-service-operations-4edeabc1d4b4>](<https://liron-marcus.medium.com/using-nlp-natural-language-processing-to-improve-field-service-operations-4edeabc1d4b4>)
- McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform manifold approximation and projection for dimension reduction. arXiv. [<https://arxiv.org/abs/1802.03426>](<https://arxiv.org/abs/1802.03426>)
- Mikolov, T., Sutskever, I., Chen, K., Corrado, G., & Dean, G. (2013). Distributed representations of words and phrases and their compositionality. arXiv. [<https://arxiv.org/abs/1310.4546>](<https://arxiv.org/abs/1310.4546>)
- Ndlovu, F. (2025). Intelligent support ticket routing with natural language processing (NLP). DEV Community. [<https://dev.to/fortune-ndlovu/intelligent-support-ticket-routing-with-natural-language-processing-nlp-57g1>](<https://dev.to/fortune-ndlovu/intelligent-support-ticket-routing-with-natural-language-processing-nlp-57g1>)
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT networks. arXiv. [<https://arxiv.org/abs/1908.10084>](<https://arxiv.org/abs/1908.10084>)
- Saha, S., Saha, A., & Shah, P. (2020). Helpdesk ticket classification using machine learning. IEEE. [<https://doi.org/10.1109/ICCCNT49239.2020.9225429>](<https://doi.org/10.1109/ICCCNT49239.2020.9225429>)
- ServiceNow. (2022). Workflow benchmark report. [<https://www.servicenow.com/now-platform/workflow-benchmark.html>](<https://www.servicenow.com/now-platform/workflow-benchmark.html>)
- Zendesk. (2021). Customer experience trends report. [<https://www.zendesk.com/resources/customer-experience-trends-report/>](<https://www.zendesk.com/resources/customer-experience-trends-report/>)